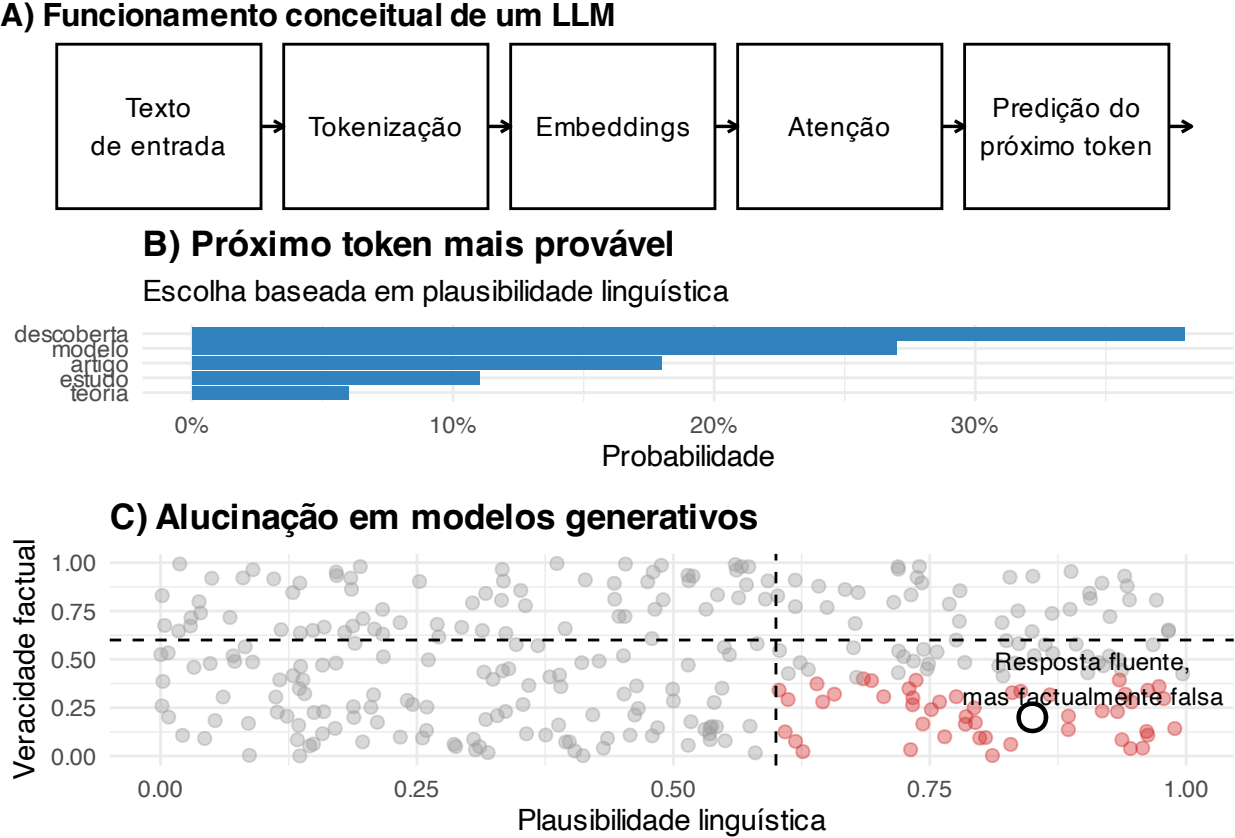
A) Funcionamento conceitual de um LLM
Texto de entrada
Tokenização
Embeddings
Atenção
Predição do próximo token
B) Próximo token mais provável
Escolha baseada em plausibilidade linguística
descoberta
modelo
artigo
estudo
teoria
0%
10%
20%
30%
Probabilidade
C) Alucinação em modelos generativos
Veracidade factual
1.00
0.75
0.50
0.25
0.00
Resposta fluente,
mas factualmente falsa
0.00
0.25
0.50
0.75
1.00
Plausibilidade linguística